

МА-процессы

Стационарные процессы

Стационарные процессы: план

- Определение стационарного процесса.

Стационарные процессы: план

- Определение стационарного процесса.
- Автоковариационная функция.

Стационарные процессы: план

- Определение стационарного процесса.
- Автоковариационная функция.
- Случайное блуждание и независимые величины.

Стационарный процесс

Случайный процесс с постоянными характеристиками.

Стационарный процесс

Случайный процесс с **постоянными характеристиками**.

Стационарность в широком смысле

Процесс (y_t) стационарен в **широком смысле**, если для любых t и k :

$$\begin{cases} \mathbb{E}(y_t) = \mu \\ \text{Cov}(y_t, y_{t+k}) = \gamma_k \end{cases}$$

Стационарный процесс

Случайный процесс с **постоянными характеристиками**.

Стационарность в широком смысле

Процесс (y_t) стационарен в **широком смысле**, если для любых t и k :

$$\begin{cases} \mathbb{E}(y_t) = \mu \\ \text{Cov}(y_t, y_{t+k}) = \gamma_k \end{cases}$$

Стационарность в узком смысле

Процесс (y_t) стационарен в **узком смысле**, если для любого k закон распределения вектора $(y_t, y_{t+1}, y_{t+2}, \dots, y_{t+k})$ не зависит от t .

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) = \dots = \gamma_2$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) = \dots = \gamma_2$$

$$\text{Cov}(y_1, y_5) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) = \dots = \gamma_2$$

$$\text{Cov}(y_1, y_5) = \text{Cov}(y_8, y_{12}) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) = \dots = \gamma_2$$

$$\text{Cov}(y_1, y_5) = \text{Cov}(y_8, y_{12}) = \text{Cov}(y_8, y_4) =$$

Стационарность: много уравнений

У стационарного процесса (y_t) :

$$\mathbb{E}(y_5) = \mathbb{E}(y_7) = \mathbb{E}(y_{100}) = \mathbb{E}(y_{135}) = \dots = \mu$$

$$\text{Var}(y_5) = \text{Var}(y_7) = \text{Var}(y_{100}) = \text{Var}(y_{135}) = \dots = \gamma_0$$

$$\text{Cov}(y_5, y_7) = \text{Cov}(y_8, y_{10}) = \text{Cov}(y_8, y_6) = \dots = \gamma_2$$

$$\text{Cov}(y_1, y_5) = \text{Cov}(y_8, y_{12}) = \text{Cov}(y_8, y_4) = \dots = \gamma_4$$

Стационарный процесс: пример

Независимые наблюдения

Величины (y_t) независимы и одинаково распределены с конечным ожиданием μ_y и конечной дисперсией σ_y^2 .

Стационарный процесс: пример

Независимые наблюдения

Величины (y_t) независимы и одинаково распределены с конечным ожиданием μ_y и конечной дисперсией σ_y^2 .

$$\mu_y = \mathbb{E}(y_t)$$

Стационарный процесс: пример

Независимые наблюдения

Величины (y_t) независимы и одинаково распределены с конечным ожиданием μ_y и конечной дисперсией σ_y^2 .

$$\mu_y = \mathbb{E}(y_t)$$

$$\gamma_0 = \text{Cov}(y_t, y_t) = \text{Var}(y_t) = \sigma_y^2.$$

Стационарный процесс: пример

Независимые наблюдения

Величины (y_t) независимы и одинаково распределены с конечным ожиданием μ_y и конечной дисперсией σ_y^2 .

$$\mu_y = \mathbb{E}(y_t)$$

$$\gamma_0 = \text{Cov}(y_t, y_t) = \text{Var}(y_t) = \sigma_y^2.$$

$$\gamma_k = \text{Cov}(y_t, y_{t+k}) = 0, \text{ при } k \geq 1.$$

Нестационарный процесс: пример

Белый шум

$$\begin{cases} y_0 = \mu \\ y_t = y_{t-1} + u_t, \text{ при } t \geq 1 \end{cases},$$

где u_t — белый шум.

Нестационарный процесс: пример

Белый шум

$$\begin{cases} y_0 = \mu \\ y_t = y_{t-1} + u_t, \text{ при } t \geq 1 \end{cases},$$

где u_t — белый шум.

В явном виде: $y_t = \mu + u_1 + u_2 + \dots + u_t$.

Нестационарный процесс: пример

Белый шум

$$\begin{cases} y_0 = \mu \\ y_t = y_{t-1} + u_t, \text{ при } t \geq 1 \end{cases},$$

где u_t — белый шум.

В явном виде: $y_t = \mu + u_1 + u_2 + \dots + u_t$.

$$\mu_y = \mathbb{E}(y_t)$$

Нестационарный процесс: пример

Белый шум

$$\begin{cases} y_0 = \mu \\ y_t = y_{t-1} + u_t, \text{ при } t \geq 1 \end{cases},$$

где u_t — белый шум.

В явном виде: $y_t = \mu + u_1 + u_2 + \dots + u_t$.

$$\mu_y = \mathbb{E}(y_t)$$

$$\gamma_0 = \text{Cov}(y_t, y_t) = \text{Var}(y_t) = \text{Var}(\mu + u_1 + \dots + u_t) = t\sigma_u^2.$$

Нестационарный процесс: пример

Белый шум

$$\begin{cases} y_0 = \mu \\ y_t = y_{t-1} + u_t, \text{ при } t \geq 1 \end{cases},$$

где u_t — белый шум.

В явном виде: $y_t = \mu + u_1 + u_2 + \dots + u_t$.

$$\mu_y = \mathbb{E}(y_t)$$

$$\gamma_0 = \text{Cov}(y_t, y_t) = \text{Var}(y_t) = \text{Var}(\mu + u_1 + \dots + u_t) = t\sigma_u^2.$$

$$\gamma_k = \text{Cov}(y_t, y_{t+k}) = \text{Cov}(y_t, y_t + u_{t+1} + \dots + u_{t+k}) = \text{Var}(y_t).$$

Белый шум и случайная выборка

тут график!

Автоковариационная функция

Определение

Для стационарного процесса (y_t) функцию

$\gamma_k = \text{Cov}(y_t, y_{t+k})$ называют автоковариационной.

Автоковариационная функция

Определение

Для стационарного процесса (y_t) функцию $\gamma_k = \text{Cov}(y_t, y_{t+k})$ называют автоковариационной.

Определение

Для стационарного процесса (y_t) функцию $\rho_k = \text{Corr}(y_t, y_{t+k})$ называют автокорреляционной.

Связь функций

$$\rho_k = \text{Corr}(y_t, y_{t+k}) = \frac{\text{Cov}(y_t, y_{t+k})}{\sqrt{\text{Var}(y_t) \text{Var}(y_{t+k})}} =$$

Связь функций

$$\rho_k = \text{Corr}(y_t, y_{t+k}) = \frac{\text{Cov}(y_t, y_{t+k})}{\sqrt{\text{Var}(y_t) \text{Var}(y_{t+k})}} = \frac{\gamma_k}{\sqrt{\gamma_0 \gamma_0}} = \frac{\gamma_k}{\gamma_0}$$

Автоковариационная функция — наше всё!

Теоремка

Если вектор $(y_t, y_{t+1}, \dots, y_{t+k})$ имеет многомерное нормальное распределение при любом количестве компонент, то константа $\mu = \mathbb{E}(y_t)$ и функция $\gamma_k = \text{Cov}(y_t, y_{t+k})$ полностью определяют конечномерные распределения случайного процесса (y_t) .

Стационарность: итоги

- Постоянные $\mathbb{E}(y_t)$, $\gamma_k = \text{Cov}(y_t, y_{t+k})$.

Стационарность: итоги

- Постоянные $\mathbb{E}(y_t)$, $\gamma_k = \text{Cov}(y_t, y_{t+k})$.
- Автоковариационная функция.

Стационарность: итоги

- Постоянные $\mathbb{E}(y_t)$, $\gamma_k = \text{Cov}(y_t, y_{t+k})$.
- Автоковариационная функция.
- Случайное блуждание нестационарно.

Стационарность: итоги

- Постоянные $\mathbb{E}(y_t)$, $\gamma_k = \text{Cov}(y_t, y_{t+k})$.
- Автоковариационная функция.
- Случайное блуждание нестационарно.
- Случайная выборка стационарна.

Частные корреляции

Частные корреляции: план

- Проекция для случайных величин.

Частные корреляции: план

- Проекция для случайных величин.
- Общее определение.

Частные корреляции: план

- Проекция для случайных величин.
- Общее определение.
- Частная автокорреляционная функция.

Геометрия случайных величин

Длина и угол

Дисперсия $\text{Var}(R)$ — **квадрат длины** случайной величины.

Корреляция $\text{Corr}(L, R)$ — **косинус угла** между случайными величинами.

Геометрия случайных величин

Длина и угол

Дисперсия $\text{Var}(R)$ — **квадрат длины** случайной величины.

Корреляция $\text{Corr}(L, R)$ — **косинус угла** между случайными величинами.

Ортогональность

Величины L и R **ортогональны**, если $\text{Cov}(L, R) = 0$.

Проекция

Обозначение

$Best(L; R_1, R_2, \dots, R_n)$ — линейная комбинация 1 и R_1, \dots, R_n , наиболее похожая на L .

Проекция

Обозначение

$Best(L; R_1, R_2, \dots, R_n)$ — линейная комбинация 1 и R_1, \dots, R_n , **наиболее** похожая на L .

$\hat{L} = Best(L; R_1, R_2, \dots, R_n)$ если:

- $\hat{L} = \alpha_0 \cdot 1 + \alpha_1 R_1 + \dots + \alpha_n R_n$;

Проекция

Обозначение

$Best(L; R_1, R_2, \dots, R_n)$ — линейная комбинация 1 и R_1, \dots, R_n , **наиболее** похожая на L .

$\hat{L} = Best(L; R_1, R_2, \dots, R_n)$ если:

- $\hat{L} = \alpha_0 \cdot 1 + \alpha_1 R_1 + \dots + \alpha_n R_n$;
- Ожидание $\mathbb{E}((L - \hat{L})^2)$ минимально.

Как найти проекцию?

Хотим найти $\hat{L} = Best(L; R_1, R_2, \dots R_n)$:

$$\hat{L} = \alpha_0 \cdot 1 + \alpha_1 R_1 + \dots + \alpha_n R_n.$$

Как найти коэффициенты?

Как найти проекцию?

Хотим найти $\hat{L} = Best(L; R_1, R_2, \dots R_n)$:

$$\hat{L} = \alpha_0 \cdot 1 + \alpha_1 R_1 + \dots + \alpha_n R_n.$$

Как найти коэффициенты?

- Минимизация:

$$\mathbb{E}((L - \hat{L})^2) \rightarrow \min$$

Как найти проекцию?

Хотим найти $\hat{L} = Best(L; R_1, R_2, \dots, R_n)$:

$$\hat{L} = \alpha_0 \cdot 1 + \alpha_1 R_1 + \dots + \alpha_n R_n.$$

Как найти коэффициенты?

- Минимизация:

$$\mathbb{E}((L - \hat{L})^2) \rightarrow \min$$

- Решение системы:

$$\begin{cases} \mathbb{E}(L) = \mathbb{E}(\hat{L}); \\ \text{Cov}(L, R_i) = \text{Cov}(\hat{L}, R_i) \text{ при всех } i; \end{cases}$$

Частная корреляция

Определение

$$\text{pCorr}(U, D; R_1, R_2, \dots, R_n) = \text{Corr}(U^*, D^*),$$

где

$$U^* = U - \text{Best}(U; R_1, R_2, \dots, R_n),$$

$$D^* = D - \text{Best}(D; R_1, R_2, \dots, R_n).$$

Частная корреляция

Определение

$$\text{pCorr}(U, D; R_1, R_2, \dots, R_n) = \text{Corr}(U^*, D^*),$$

где

$$U^* = U - \text{Best}(U; R_1, R_2, \dots, R_n),$$

$$D^* = D - \text{Best}(D; R_1, R_2, \dots, R_n).$$

Величины U^* и D^* — это **очищенные** версии U и D .

$$\text{Cov}(U^*, R_i) = 0, \quad \text{Cov}(D^*, R_i) = 0.$$

Два угла на графике

обычная и частная корреляции

Определение

Для стационарного процесса (y_t) функцию

$$\varphi_{kk} = \text{pCorr}(y_t, y_{t+k}; y_{t+1}, \dots, y_{t+k-1}).$$

называют **частной автокорреляционной**.

ACF и PACF: интуиция

Для **стационарного процесса**!

- ACF:

$$\rho_k = \text{Corr}(y_t, y_{t+k}).$$

Общая сила связи y_t и y_{t+k} .

- PACF:

$$\varphi_{kk} = \text{pCorr}(y_t, y_{t+k}; y_{t+1}, \dots, y_{t+k-1}).$$

Сила связи y_t и y_{t+k} при **разорванных** связях через промежуточные наблюдения.

Почему двойной индекс?

$$\varphi_{33} = \text{pCorr}(y_t, y_{t+3}; y_{t+1}, y_{t+2}).$$

Почему двойной индекс?

$$\varphi_{33} = \text{pCorr}(y_t, y_{t+3}; y_{t+1}, y_{t+2}).$$

$$\varphi_{23} = \text{pCorr}(y_t, y_{t+2}; y_{t+1}, y_{t+3}).$$

Почему двойной индекс?

$$\varphi_{33} = \text{pCorr}(y_t, y_{t+3}; y_{t+1}, y_{t+2}).$$

$$\varphi_{23} = \text{pCorr}(y_t, y_{t+2}; y_{t+1}, y_{t+3}).$$

$$\varphi_{13} = \text{pCorr}(y_t, y_{t+1}; y_{t+2}, y_{t+3}).$$

Выборочная PACF через остатки

Корреляция остатков

$PACF_4$ — выборочная корреляция между остатками a_t и остатками b_t .

a_t — остатки из регрессии

y_t на $1, y_{t-1}, y_{t-2}, y_{t-3}$.

b_t — остатки из регрессии

y_{t-4} на $1, y_{t-1}, y_{t-2}, y_{t-3}$.

Выборочная PACF через коэффициент

Оценка коэффициента

$PACF_4$ — оценка последнего коэффициента в множественной регрессии:

$$\hat{y}_t = \hat{\beta} + \hat{\beta}_1 y_{t-1} + \dots + \hat{\beta}_4 y_{t-4}, \quad PACF_4 = \hat{\beta}_4.$$

Выборочная и истинная PACF

- Истинная PACF есть только у стационарного процесса.

Выборочная и истинная PACF

- Истинная PACF есть **только у стационарного** процесса.
- Выборочную PACF можно посчитать **у любого** процесса.

Выборочная и истинная PACF

- Истинная PACF есть **только у стационарного** процесса.
- Выборочную PACF можно посчитать **у любого** процесса.
- По выборочной PACF иногда **можно судить** о стационарности.

Выборочная и истинная PACF

- Истинная PACF есть **только у стационарного** процесса.
- Выборочную PACF можно посчитать **у любого** процесса.
- По выборочной PACF иногда **можно судить** о стационарности.
- Оба способа дают состоятельные оценки для стационарного процесса.

Выборочная и истинная PACF

- Истинная PACF есть **только у стационарного** процесса.
- Выборочную PACF можно посчитать **у любого** процесса.
- По выборочной PACF иногда **можно судить** о стационарности.
- Оба способа дают состоятельные оценки для стационарного процесса.
- Способ с выборочной корреляцией остатков гарантирует числа из отрезка $[-1; 1]$.

Частная корреляция: итоги

- Ковариация задаёт геометрию.

Частная корреляция: итоги

- Ковариация задаёт геометрию.
- Частная корреляция — корреляция **очищенных** величин.

Частная корреляция: итоги

- Ковариация задаёт геометрию.
- Частная корреляция — корреляция **очищенных** величин.
- Во временных рядах очищаем два наблюдения от **промежуточных**.

Частная корреляция: итоги

- Ковариация задаёт геометрию.
- Частная корреляция — корреляция **очищенных** величин.
- Во временных рядах очищаем два наблюдения от **промежуточных**.
- Оцениваем частную корреляцию.

ETS(AAA)

ETS(AAA): план

- Добавляем сезонность в ETS!

ETS(AAA): план

- Добавляем сезонность в ETS!
- Прогнозы.

ETS(AAA): план

- Добавляем сезонность в ETS!
- Прогнозы.
- Разложение на составляющие.

Добавляем сезонность!

y_t — наблюдаемый ряд;

ℓ_t — тренд, очищенный ряд (единорог);

b_t — текущая скорость роста очищенного ряда (единорог);

s_t — сезонная составляющая (единорог);

u_t — случайная ошибка.

Добавляем сезонность!

y_t — наблюдаемый ряд;

ℓ_t — тренд, очищенный ряд (единорог);

b_t — текущая скорость роста очищенного ряда (единорог);

s_t — сезонная составляющая (единорог);

u_t — случайная ошибка.

ETS(AAA):

A — аддитивная ошибка;

A — аддитивный тренд;

A — аддитивная сезонность.

ETS(AAA): уравнения

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t; \text{ стартовые } s_0, s_{-1}, \dots, s_{-11}. \end{array} \right.$$

ETS(AAA): уравнения

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t; \text{ стартовые } s_0, s_{-1}, \dots, s_{-11}. \end{array} \right.$$

Параметры: $\alpha, \beta, \gamma, \sigma^2, \ell_0, b_0, s_0, s_{-1}, \dots, s_{-11}$.

Ограничение: $s_0 + s_{-1} + \dots + s_{-11} = 0$.

ETS(AAA): сколько параметров?

Параметры: $\alpha, \beta, \gamma, \sigma^2, \ell_0, b_0, s_0, s_{-1}, \dots, s_{-11}$.

Ограничение: $s_0 + s_{-1} + \dots + s_{-11} = 0$.

Сколько независимых параметров оцениваем?

ETS(AAA): сколько параметров?

Параметры: $\alpha, \beta, \gamma, \sigma^2, \ell_0, b_0, s_0, s_{-1}, \dots, s_{-11}$.

Ограничение: $s_0 + s_{-1} + \dots + s_{-11} = 0$.

Сколько независимых параметров оцениваем?

Правильный ответ: 17.

ETS(AAA): прогнозируем

Картинка с прогнозами на 12 шагов вперед

Прогноз на 1 шаг вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

Прогноз на 1 шаг вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

$$y_{T+1} = \ell_T + b_T + s_{T-11} + u_{T+1}$$

Прогноз на 1 шаг вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

$$y_{T+1} = \ell_T + b_T + s_{T-11} + u_{T+1}$$

$$(y_{T+1} \mid \mathcal{F}_T) \sim \mathcal{N}(\ell_T + b_T + s_{T-11}; \sigma^2)$$

Прогноз на 2 шага вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

Прогноз на 2 шага вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

$$y_{T+2} = \ell_{T+1} + b_{T+1} + s_{T-10} + u_{T+2} = (\ell_T + b_T + \alpha u_{T+1}) + \\ + (b_T + \beta u_{T+1}) + s_{T-10} + u_{T+2}$$

Прогноз на 2 шага вперёд

$$\left\{ \begin{array}{l} y_t = \ell_{t-1} + b_{t-1} + s_{t-12} + u_t; \\ \ell_t = \ell_{t-1} + b_{t-1} + \alpha u_t, \text{ стартовое } \ell_0; \\ u_t \sim \mathcal{N}(0; \sigma^2) \text{ и независимы.} \\ b_t = b_{t-1} + \beta u_t, \text{ стартовое } b_0; \\ s_t = s_{t-12} + \gamma u_t \end{array} \right.$$

$$y_{T+2} = \ell_{T+1} + b_{T+1} + s_{T-10} + u_{T+2} = (\ell_T + b_T + \alpha u_{T+1}) + \\ + (b_T + \beta u_{T+1}) + s_{T-10} + u_{T+2}$$

$$(y_{T+2} \mid \mathcal{F}_T) \sim \mathcal{N}(\ell_T + 2b_T + s_{T-10}; \sigma^2((\alpha + \beta)^2 + 1))$$

Попутное разложение!

На выходе ETS(AAA):

Оценки параметров: $\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{\sigma}^2, \hat{\ell}_0, \hat{b}_0, \hat{s}_0, \hat{s}_{-1}, \dots, \hat{s}_{-11}$.

Ограничение: $\hat{s}_0 + \hat{s}_{-1} + \dots + \hat{s}_{-11} = 0$.

Попутное разложение!

На выходе ETS(AAA):

Оценки параметров: $\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{\sigma}^2, \hat{\ell}_0, \hat{b}_0, \hat{s}_0, \hat{s}_{-1}, \dots, \hat{s}_{-11}$.

Ограничение: $\hat{s}_0 + \hat{s}_{-1} + \dots + \hat{s}_{-11} = 0$.

Оценённые значения составляющих: $\hat{\ell}_t, \hat{b}_t, \hat{s}_t$.

Попутное разложение!

На выходе ETS(AAA):

Оценки параметров: $\hat{\alpha}, \hat{\beta}, \hat{\gamma}, \hat{\sigma}^2, \hat{\ell}_0, \hat{b}_0, \hat{s}_0, \hat{s}_{-1}, \dots, \hat{s}_{-11}$.

Ограничение: $\hat{s}_0 + \hat{s}_{-1} + \dots + \hat{s}_{-11} = 0$.

Оценённые значения составляющих: $\hat{\ell}_t, \hat{b}_t, \hat{s}_t$.

Автоматически получаем разложение:

$$y_t = \hat{\ell}_t + \hat{s}_t + remainder_t.$$

ETS(AAA): итоги

- Ух, целых 17 параметров!

ETS(AAA): итоги

- Ух, целых 17 параметров!
- Наклон линии тренда и сезонность могут меняться.

ETS(AAA): итоги

- Ух, целых 17 параметров!
- Наклон линии тренда и сезонность могут меняться.
- Автоматическое разложение на составляющие.

Новые модели из старых

Новые модели из старых: план

- Преобразование переменной.

Новые модели из старых: план

- Преобразование переменной.
- Разница между ожиданием и медианой.

Новые модели из старых: план

- Преобразование переменной.
- Разница между ожиданием и медианой.
- Усреднение моделей.

Преобразование переменной

Помимо модели $y_t \sim ETS(AAA)$ можно оценить:

Преобразование переменной

Помимо модели $y_t \sim ETS(AAA)$ можно оценить:

вторую модель $\ln y_t \sim ETS(AAA)$ или

Преобразование переменной

Помимо модели $y_t \sim ETS(AAA)$ можно оценить:

вторую модель $\ln y_t \sim ETS(AAA)$ или третью модель $\sqrt{y_t} \sim ETS(AAA)$.

Преобразование переменной

Помимо модели $y_t \sim ETS(AAA)$ можно оценить:

вторую модель $\ln y_t \sim ETS(AAA)$ или третью модель $\sqrt{y_t} \sim ETS(AAA)$.

Чтобы сравнивать прогнозы моделей, нужно работать в общем масштабе!

Преобразование переменной

Помимо модели $y_t \sim ETS(AAA)$ можно оценить:

вторую модель $\ln y_t \sim ETS(AAA)$ или третью модель $\sqrt{y_t} \sim ETS(AAA)$.

Чтобы сравнивать прогнозы моделей, нужно работать в общем масштабе!

В зависимости от софта: либо сами приводим к исходным единицам, либо это происходит автоматически.

Преобразование Бокса-Кокса

Для y_t , чей размах колебаний растёт с ростом y_t , разумно попробовать логарифм или преобразование Бокса-Кокса.

Преобразование Бокса-Кокса

Для y_t , чей размах колебаний растёт с ростом y_t , разумно попробовать логарифм или преобразование Бокса-Кокса.

Логарифм: $y_t \rightarrow \ln y_t$.

Преобразование Бокса-Кокса: $y_t \rightarrow bc_\lambda(y_t)$.

Преобразование Бокса-Кокса

Для y_t , чей размах колебаний растёт с ростом y_t , **разумно попробовать** логарифм или преобразование Бокса-Кокса.

Логарифм: $y_t \rightarrow \ln y_t$.

Преобразование Бокса-Кокса: $y_t \rightarrow bc_\lambda(y_t)$.

(Обобщённое) преобразование Бокса-Кокса:

$$bc_\lambda(y_t) = \begin{cases} \ln y_t, & \text{если } \lambda = 0, \\ \text{sign}(y_t)(|y_t|^\lambda - 1)/\lambda, & \text{если } \lambda \neq 0. \end{cases}$$

Параметр лямбда

Как **выбрать** параметр λ для перехода $y_t \rightarrow bc_\lambda(y_t)$?

$$bc_\lambda(y_t) = \begin{cases} \ln y_t, & \text{если } \lambda = 0, \\ \text{sign}(y_t)(|y_t|^\lambda - 1)/\lambda, & \text{если } \lambda \neq 0. \end{cases}$$

Параметр лямбда

Как **выбрать** параметр λ для перехода $y_t \rightarrow bc_\lambda(y_t)$?

$$bc_\lambda(y_t) = \begin{cases} \ln y_t, & \text{если } \lambda = 0, \\ \text{sign}(y_t)(|y_t|^\lambda - 1)/\lambda, & \text{если } \lambda \neq 0. \end{cases}$$

- Некоторые модели содержат его внутри себя и **сами подбирают** λ .

Параметр лямбда

Как **выбрать** параметр λ для перехода $y_t \rightarrow bc_\lambda(y_t)$?

$$bc_\lambda(y_t) = \begin{cases} \ln y_t, & \text{если } \lambda = 0, \\ \text{sign}(y_t)(|y_t|^\lambda - 1)/\lambda, & \text{если } \lambda \neq 0. \end{cases}$$

- Некоторые модели содержат его внутри себя и **сами подбирают** λ .
- Можно подобрать λ самостоятельно, чтобы **стабилизировать амплитуду** колебаний ряда.

Разница между медианой и ожиданием

Для модели $y_t \sim ETS(AAA)$ прогноз $\hat{y}_{t+h|t}$ означает **две величины**:

- Ожидание $\mathbb{E}(y_{t+h} \mid \mathcal{F}_t)$;
- Медиана $\text{Med}(y_{t+h} \mid \mathcal{F}_t)$.

Разница между медианой и ожиданием

Для модели $y_t \sim ETS(AAA)$ прогноз $\hat{y}_{t+h|t}$ означает **две величины**:

- Ожидание $\mathbb{E}(y_{t+h} \mid \mathcal{F}_t)$;
- Медиана $\text{Med}(y_{t+h} \mid \mathcal{F}_t)$.

Для модели $\ln y_t \sim ETS(AAA)$ ожидание и медиана **не совпадают!**

$$\mathbb{E}(y_{t+h} \mid \mathcal{F}_t) \neq \text{Med}(y_{t+h} \mid \mathcal{F}_t).$$

Разница между медианой и ожиданием

Для модели $y_t \sim ETS(AAA)$ прогноз $\hat{y}_{t+h|t}$ означает **две величины**:

- Ожидание $\mathbb{E}(y_{t+h} \mid \mathcal{F}_t)$;
- Медиана $\text{Med}(y_{t+h} \mid \mathcal{F}_t)$.

Для модели $\ln y_t \sim ETS(AAA)$ ожидание и медиана **не совпадают!**

$$\mathbb{E}(y_{t+h} \mid \mathcal{F}_t) \neq \text{Med}(y_{t+h} \mid \mathcal{F}_t).$$

Если $Z \sim \mathcal{N}(\mu, \sigma^2)$, то:

$$\text{Med}(e^Z) = \exp(\mu), \quad \mathbb{E}(e^Z) = \exp(\mu) \cdot \exp(\sigma^2/2).$$

Преобразование предиктивного интервала

Построили предиктивный интервал для $z_t = \ln y_t$:

$$z_{T+1} \in [z_{left}; z_{right}].$$

Преобразование предиктивного интервала

Построили предиктивный интервал для $z_t = \ln y_t$:

$$z_{T+1} \in [z_{left}; z_{right}].$$

Преобразование **естественное**:

$$y_{T+1} \in [\exp(z_{left}); \exp(z_{right})].$$

Преобразование предиктивного интервала

Построили предиктивный интервал для $z_t = \ln y_t$:

$$z_{T+1} \in [z_{left}; z_{right}].$$

Преобразование **естественное**:

$$y_{T+1} \in [\exp(z_{left}); \exp(z_{right})].$$

Предиктивный интервал для y_{T+1} **не симметричен** ни относительно ожидания, ни относительно медианы.

Усредняем модели!

Есть две модели $y_t \sim \text{Model A}$, $y_t \sim \text{Model B}$.

Усредняем модели!

Есть две модели $y_t \sim \text{Model A}$, $y_t \sim \text{Model B}$.

Создаём усреднённый алгоритм:

$$y_t \sim \frac{\text{Model A} + \text{Model B}}{2} = \text{Algorithm C}.$$

Усредняем модели!

Есть две модели $y_t \sim \text{Model A}$, $y_t \sim \text{Model B}$.

Создаём **усреднённый алгоритм**:

$$y_t \sim \frac{\text{Model A} + \text{Model B}}{2} = \text{Algorithm C}.$$

Точечные прогнозы считаем как **среднее** прогнозов:

$$\hat{y}_{t+h|t}^c = \frac{\hat{y}_{t+h|t}^a + \hat{y}_{t+h|t}^b}{2}.$$

Усредняем модели!

Есть две модели $y_t \sim \text{Model A}$, $y_t \sim \text{Model B}$.

Создаём **усреднённый алгоритм**:

$$y_t \sim \frac{\text{Model A} + \text{Model B}}{2} = \text{Algorithm C}.$$

Точечные прогнозы считаем как **среднее** прогнозов:

$$\hat{y}_{t+h|t}^c = \frac{\hat{y}_{t+h|t}^a + \hat{y}_{t+h|t}^b}{2}.$$

Строго говоря, это — **алгоритм**.

Маленькое чудо!

Усреднённая модель **может быть лучше** каждой из усредняемых.

Маленькое чудо!

Усреднённая модель **может быть лучше** каждой из усредняемых.

Разложение на дисперсию и смещение:

$$\mathbb{E}((y_{t+h} - \hat{y}_{t+h|t})^2) = \text{Var}(y_{t+h} - \hat{y}_{t+h|t}) + (\mathbb{E}(y_{t+h} - \hat{y}_{t+h|t}))^2.$$

Маленькое чудо!

Усреднённая модель **может быть лучше** каждой из усредняемых.

Разложение на дисперсию и смещение:

$$\mathbb{E}((y_{t+h} - \hat{y}_{t+h|t})^2) = \text{Var}(y_{t+h} - \hat{y}_{t+h|t}) + (\mathbb{E}(y_{t+h} - \hat{y}_{t+h|t}))^2.$$

Для **несмещённых** моделей усреднение может снизить дисперсию ошибки прогноза.

Новые модели из старых: итоги

- Преобразование переменных: логарифм, преобразование Бокса-Кокса.

Новые модели из старых: итоги

- Преобразование переменных: логарифм, преобразование Бокса-Кокса.
- Разница между ожиданием и медианой.

Новые модели из старых: итоги

- Преобразование переменных: логарифм, преобразование Бокса-Кокса.
- Разница между ожиданием и медианой.
- Усреднение моделей.

Сравнение моделей

Сравнение моделей: план

- MAE и ещё куча страшных слов.

Сравнение моделей: план

- MAE и ещё куча страшных слов.
- Кросс-валидация.

Сравнение моделей: план

- MAE и ещё куча страшных слов.
- Кросс-валидация.
- Критерий Акаике.

Помните о цели!

Если цель построения модели — прогнозы на один шаг вперёд, то разумно сравнивать модели по прогнозной силе на один шаг вперёд.

Помните о цели!

Если цель построения модели — прогнозы на один шаг вперёд, то разумно сравнивать модели по прогнозной силе на один шаг вперёд.

Если цель — обнаружить момент разладки, то разумно искать модель дающую минимальную ошибку, когда нет разладки, и максимальную ошибку, когда разладка есть.

Обозначения для краткости

Для прогноза важно, **когда** его строят, и на **сколько шагов** **вперёд**:

$$\hat{y}_{t+h|t}.$$

Обозначения для краткости

Для прогноза важно, **когда** его строят, и на **сколько шагов** **вперёд**:

$$\hat{y}_{t+h|t}.$$

Иногда для **краткости**:

$$\hat{y}_{t+h}$$

Обозначения для краткости

Для прогноза важно, **когда** его строят, и на **сколько шагов вперёд**:

$$\hat{y}_{t+h|t}.$$

Иногда для **краткости**:

$$\hat{y}_{t+h}$$

Проблемка:

$$\hat{y}_{(t+1)+2} \neq \hat{y}_{(t+2)+1}.$$

Показатели антикачества

Ошибка прогноза: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$.

Показатели антикачества

Ошибка прогноза: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$.

Средняя абсолютная ошибка (Mean Absolute Error):

$$MAE = \frac{|e_{T+1}| + |e_{T+1}| + \dots + |e_{T+H}|}{H}.$$

Показатели антикачества

Ошибка прогноза: $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$.

Средняя абсолютная ошибка (Mean Absolute Error):

$$MAE = \frac{|e_{T+1}| + |e_{T+1}| + \dots + |e_{T+H}|}{H}.$$

Средняя квадратичная ошибка (Root Mean Squared Error):

$$RMSE = \sqrt{\frac{e_{T+1}^2 + e_{T+1}^2 + \dots + e_{T+H}^2}{H}}.$$

Масштабируем

Переводим ошибку $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$ в проценты

$$p_t = e_t / y_t \cdot 100 \text{ или } p_t^s = e_t / (0.5y_t + 0.5\hat{y}_t) \cdot 100.$$

Масштабируем

Переводим ошибку $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$ в проценты

$p_t = e_t/y_t \cdot 100$ или $p_t^s = e_t/(0.5y_t + 0.5\hat{y}_t) \cdot 100$.

Средняя абсолютная процентная ошибка (Mean Absolute Percentage Error):

$$MAPE = \frac{|p_{T+1}| + |p_{T+1}| + \dots + |p_{T+H}|}{H}.$$

Масштабируем

Переводим ошибку $e_{t+h} = y_{t+h} - \hat{y}_{t+h}$ в проценты

$p_t = e_t/y_t \cdot 100$ или $p_t^s = e_t/(0.5y_t + 0.5\hat{y}_t) \cdot 100$.

Средняя абсолютная процентная ошибка (Mean Absolute Percentage Error):

$$MAPE = \frac{|p_{T+1}| + |p_{T+1}| + \dots + |p_{T+H}|}{H}.$$

Симметричная средняя абсолютная процентная ошибка (Symmetric Mean Absolute Percentage Error):

$$sMAPE = \frac{|p_{T+1}^s| + |p_{T+1}^s| + \dots + |p_{T+H}^s|}{H}.$$

Автоматически сравниваем с наивной

Наивный прогноз: $\hat{y}_t^{naive} = y_{t-1}$ или $\hat{y}_t^{naive} = y_{t-12}$.

Автоматически сравниваем с наивной

Наивный прогноз: $\hat{y}_t^{naive} = y_{t-1}$ или $\hat{y}_t^{naive} = y_{t-12}$.

Отмасштабируем ошибку нашего прогноза e_t к MAE^{naive} :

$$q_t = \frac{e_t}{MAE^{naive}}.$$

Автоматически сравниваем с наивной

Наивный прогноз: $\hat{y}_t^{naive} = y_{t-1}$ или $\hat{y}_t^{naive} = y_{t-12}$.

Отмасштабируем ошибку нашего прогноза e_t к MAE^{naive} :

$$q_t = \frac{e_t}{MAE^{naive}}.$$

Средняя абсолютная отмасштабированная ошибка (Mean Absolute Scaled Error):

$$MASE = \frac{|q_{T+1}| + |q_{T+1}| + \dots + |q_{T+H}|}{H}.$$

Автоматически сравниваем с наивной

Наивный прогноз: $\hat{y}_t^{naive} = y_{t-1}$ или $\hat{y}_t^{naive} = y_{t-12}$.

Отмасштабируем ошибку нашего прогноза e_t к MAE^{naive} :

$$q_t = \frac{e_t}{MAE^{naive}}.$$

Средняя абсолютная отмасштабированная ошибка (Mean Absolute Scaled Error):

$$MASE = \frac{|q_{T+1}| + |q_{T+1}| + \dots + |q_{T+H}|}{H}.$$

Сравнение q с единицей сравнивает нашу модель с наивной.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на обучающую (в начале) и тестовую (в конце).

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** каждое наблюдение тестовой выборки с помощью каждой модели.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** каждое наблюдение тестовой выборки с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** каждое наблюдение тестовой выборки с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сравниваем** модели по MAE и выбираем лучшую.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** каждое наблюдение тестовой выборки с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сравниваем** модели по MAE и выбираем лучшую.

Обучающая и тестовая выборка

Стратегия:

1. Делим всю выборку на **обучающую** (в начале) и **тестовую** (в конце).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** каждое наблюдение тестовой выборки с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сравниваем** модели по MAE и выбираем лучшую.

Недостаток: **у прогнозов разный горизонт.**

Деление на обучающую и тестовую

картинка с растущими стрелочками-параболками

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер обучающей выборки (в начале).

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** на один шаг вперёд с помощью каждой модели.

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** на один шаг вперёд с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** на один шаг вперёд с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сдвигаем** обучающую выборку на одно наблюдение вправо.

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** на один шаг вперёд с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сдвигаем** обучающую выборку на одно наблюдение вправо.
6. Повторяем шаги 2-5.

Кросс-валидация скользящим окном

Стратегия:

1. Выбираем стартовый размер **обучающей** выборки (в начале).
2. **Оцениваем** несколько моделей по обучающей выборке.
3. **Прогнозируем** на один шаг вперёд с помощью каждой модели.
4. Рассчитываем **ошибки** прогнозов моделей.
5. **Сдвигаем** обучающую выборку на одно наблюдение вправо.
6. Повторяем шаги 2-5.
7. **Сравниваем** модели по MAE и выбираем лучшую.

Кросс-валидация скользящим окном

картинка с растущими стрелочками-параболками

Кросс-валидация растущим окном

Стратегия:

1. Выбираем стартовый размер обучающей выборки (в начале).
2. Оцениваем несколько моделей по обучающей выборке.
3. Прогнозируем на один шаг вперёд с помощью каждой модели.
4. Рассчитываем ошибки прогнозов моделей.
5. Увеличиваем обучающую выборку на одно наблюдение.
6. Повторяем шаги 2-5.
7. Сравниваем модели по MAE и выбираем лучшую.

Кросс-валидация растущим окном

картинка с растущими стрелочками-параболками

Кросс-валидация: обсуждение

Кросс-валидация **скользящим** окном: наблюдений много и мы подозреваем, что зависимость изменяется.

Кросс-валидация: обсуждение

Кросс-валидация **скользящим** окном: наблюдений много и мы подозреваем, что зависимость изменяется.

Кросс-валидация **растущим** окном: наблюдений мало или мы уверены в том, что зависимость сохраняется.

Кросс-валидация: обсуждение

Кросс-валидация **скользящим** окном: наблюдений много и мы подозреваем, что зависимость изменяется.

Кросс-валидация **растущим** окном: наблюдений мало или мы уверены в том, что зависимость сохраняется.

Кросс-валидация — может быть долгой!

Сделаем кросс-валидацию по-быстрому!

Примерная замена кросс-валидации на один шаг вперёд по $RMSE$.

Критерий Акаике (Akaike Information Criterion):

Сделаем кросс-валидацию по-быстрому!

Примерная замена кросс-валидации на один шаг вперёд по $RMSE$.

Критерий Акаике (Akaike Information Criterion):

$$AIC = -2 \ln L + 2k,$$

где $\ln L$ — логарифм максимума правдоподобия на обучающей выборке, k — общее число параметров модели.

Нюансы AIC

- AIC имеет теоретические основания:

$$\frac{AIC_A - AIC_B}{2} \approx KL(\text{Truth} || \text{Model A}) - KL(\text{Truth} || \text{Model B}).$$

Нюансы AIC

- AIC имеет теоретические основания:

$$\frac{AIC_A - AIC_B}{2} \approx KL(\text{Truth} || \text{Model A}) - KL(\text{Truth} || \text{Model B}).$$

- Может использоваться для невложенных моделей.

Нюансы AIC

- AIC имеет теоретические основания:

$$\frac{AIC_A - AIC_B}{2} \approx KL(\text{Truth} || \text{Model A}) - KL(\text{Truth} || \text{Model B}).$$

- Может использоваться для невложенных моделей.
- Для гауссовских моделей y_t критерий аппроксимирует сравнение по $RMSE$.

Нюансы AIC

- AIC имеет теоретические основания:

$$\frac{AIC_A - AIC_B}{2} \approx KL(\text{Truth} || \text{Model A}) - KL(\text{Truth} || \text{Model B}).$$

- Может использоваться для невложенных моделей.
- Для гауссовских моделей y_t критерий аппроксимирует сравнение по $RMSE$.
- Сравнимые модели должны моделировать те же наблюдения.

Нюансы AIC

- AIC имеет теоретические основания:

$$\frac{AIC_A - AIC_B}{2} \approx KL(\text{Truth} || \text{Model A}) - KL(\text{Truth} || \text{Model B}).$$

- Может использоваться для невложенных моделей.
- Для гауссовских моделей y_t критерий аппроксимирует сравнение по $RMSE$.
- Сравниваемые модели должны моделировать те же наблюдения.
- Разный софт может исключать из правдоподобия разные константы.

Сравнение моделей: итоги

- MAE, RMSE, MAPE, MASE.

Сравнение моделей: итоги

- MAE, RMSE, MAPE, MASE.
- Кросс-валидация: скользящее и растущее окно.

Сравнение моделей: итоги

- MAE, RMSE, MAPE, MASE.
- Кросс-валидация: скользящее и растущее окно.
- AIC — быстрый примерный аналог кросс-валидации.