

Добавляем предикторы

Как обойтись без моделей?

Обойтись без моделей: план

- Как переделать временные ряды в перекрестные данные?

Обойтись без моделей: план

- Как переделать временные ряды в перекрестные данные?
- Добавить лаги переменной y_t .

Обойтись без моделей: план

- Как переделать временные ряды в перекрестные данные?
- Добавить лаги переменной y_t .
- Использовать агрегирующие функции и скользящее или растущее окно.

Как обойтись без моделей?

Старые друзья

Есть алгоритмы, которые по обучающей выборке зависимой переменной y , обучающей матрице предикторов X , и новым предикторам X_F строят прогноз \hat{y}_F .

Как обойтись без моделей?

Старые друзья

Есть алгоритмы, которые по обучающей выборке зависимой переменной y , обучающей матрице предикторов X , и новым предикторам X_F строят прогноз \hat{y}_F .

Случайный лес, градиентный бустинг...

Как обойтись без моделей?

Старые друзья

Есть алгоритмы, которые по обучающей выборке зависимой переменной y , обучающей матрице предикторов X , и новым предикторам X_F строят прогноз \hat{y}_F .

Случайный лес, градиентный бустинг... и даже обычная регрессия!

Как обойтись без моделей?

Старые друзья

Есть алгоритмы, которые по обучающей выборке зависимой переменной y , обучающей матрице предикторов X , и новым предикторам X_F строят прогноз \hat{y}_F .

Случайный лес, градиентный бустинг... и даже обычная регрессия!

Можно усреднять прогнозы ARIMA/ETS и прогнозы других алгоритмов.

Как создать предикторы?

Из одного столбца y можно создать целую матрицу X предикторов!

- Использовать лаги y_{t-k} .

Как создать предикторы?

Из одного столбца y можно создать целую матрицу X предикторов!

- Использовать лаги y_{t-k} .
- Использовать функции от лагов в качестве предикторов.

Используем лаги y

Для примера возьмём два лага, Ly_t и L^2y_t .

Используем лаги y

Для примера возьмём два лага, Ly_t и L^2y_t .

Обучающая выборка:

$$\begin{pmatrix} y_3 \\ y_4 \\ y_5 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} y_1 & y_2 \\ y_2 & y_3 \\ y_3 & y_4 \\ \vdots & \vdots \\ y_{T-2} & y_{T-1} \end{pmatrix}$$

Используем лаги y

Для примера возьмём два лага, Ly_t и L^2y_t .

Обучающая выборка:

$$\begin{pmatrix} y_3 \\ y_4 \\ y_5 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} y_1 & y_2 \\ y_2 & y_3 \\ y_3 & y_4 \\ \vdots & \vdots \\ y_{T-2} & y_{T-1} \end{pmatrix}$$

Выборка для прогнозирования:

$$\begin{pmatrix} ? \end{pmatrix} \quad \begin{pmatrix} y_{T-1} & y_T \end{pmatrix}$$

Сколько лагов добавить?

- Каждый добавленный лаг **сокращает** обучающую выборку!

Сколько лагов добавить?

- Каждый добавленный лаг **сокращает** обучающую выборку!
- Разумно добавить **ближайшие лаги** Ly_t, L^2y_t .

Сколько лагов добавить?

- Каждый добавленный лаг **сокращает** обучающую выборку!
- Разумно добавить **ближайшие лаги** Ly_t, L^2y_t .
- Для сезонных данных разумно добавить **сезонный лаг** $L^{12}y_t$.

Сколько лагов добавить?

- Каждый добавленный лаг **сокращает** обучающую выборку!
- Разумно добавить **ближайшие лаги** Ly_t, L^2y_t .
- Для сезонных данных разумно добавить **сезонный лаг** $L^{12}y_t$.
- Есть алгоритмы **чувствительные к лишним предикторам**: например, регрессия.

Сколько лагов добавить?

- Каждый добавленный лаг **сокращает** обучающую выборку!
- Разумно добавить **ближайшие лаги** Ly_t, L^2y_t .
- Для сезонных данных разумно добавить **сезонный лаг** $L^{12}y_t$.
- Есть алгоритмы **чувствительные к лишним предикторам**: например, регрессия.
- Есть алгоритмы **нечувствительные к лишним предикторам**: например, случайный лес.

Функции от лагов

При прогнозировании y_t **честно** использовать любую функцию от **предыдущих** y_{t-1}, y_{t-2}, \dots

Функции от лагов

При прогнозировании y_t **честно** использовать любую функцию от **предыдущих** y_{t-1}, y_{t-2}, \dots

Например:

- $\Delta y_{t-1} = y_{t-1} - y_{t-2}$;

Функции от лагов

При прогнозировании y_t **честно** использовать любую функцию от **предыдущих** y_{t-1}, y_{t-2}, \dots

Например:

- $\Delta y_{t-1} = y_{t-1} - y_{t-2};$
- $\max\{y_{t-1}, y_{t-2}, y_{t-3}\};$

Функции от лагов

При прогнозировании y_t **честно** использовать любую функцию от **предыдущих** y_{t-1}, y_{t-2}, \dots

Например:

- $\Delta y_{t-1} = y_{t-1} - y_{t-2}$;
- $\max\{y_{t-1}, y_{t-2}, y_{t-3}\}$;
- $\min\{y_{t-1}, y_{t-2}, \dots, y_1\}$.

Типичный предиктор

- Агрегирующая функция:

Минимум, максимум, среднее, медиана, размах, выборочная дисперсия, выборочное стандартное отклонение, ...

Типичный предиктор

- **Агрегирующая функция:**

Минимум, максимум, среднее, медиана, размах, выборочная дисперсия, выборочное стандартное отклонение, ...

- **Аргумент** агрегирующей функции:

Скользящее окно: агрегирующая функция применяется, скажем, к трём предыдущим значениям y_{t-1} , y_{t-2} , y_{t-3} .

Растущее окно: агрегирующая функция применяется ко всем предыдущим значениям y_{t-1} , y_{t-2} , ..., y_1 .

Используем функции лагов *y*

Для примера возьмём максимум скользящим окном и минимум растущим окном.

Используем функции лагов y

Для примера возьмём максимум скользящим окном и минимум растущим окном.

Обучающая выборка:

$$\begin{pmatrix} y_3 \\ y_4 \\ y_5 \\ \vdots \\ y_T \end{pmatrix} \begin{pmatrix} \max\{y_1, y_2\} & \min\{y_1, y_2\} \\ \max\{y_2, y_3\} & \min\{y_1, y_2, y_3\} \\ \max\{y_3, y_4\} & \min\{y_1, \dots, y_4\} \\ \vdots & \vdots \\ \max\{y_{T-2}, y_{T-1}\} & \min\{y_1, \dots, y_{T-1}\} \end{pmatrix}$$

Используем функции лагов y

Для примера возьмём максимум скользящим окном и минимум растущим окном.

Обучающая выборка:

$$\begin{pmatrix} y_3 \\ y_4 \\ y_5 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} \max\{y_1, y_2\} & \min\{y_1, y_2\} \\ \max\{y_2, y_3\} & \min\{y_1, y_2, y_3\} \\ \max\{y_3, y_4\} & \min\{y_1, \dots, y_4\} \\ \vdots & \vdots \\ \max\{y_{T-2}, y_{T-1}\} & \min\{y_1, \dots, y_{T-1}\} \end{pmatrix}$$

Выборка для прогнозирования:

$$\begin{pmatrix} ? \end{pmatrix} \quad \begin{pmatrix} \max\{y_{T-1}, y_T\} & \min\{y_1, \dots, y_T\} \end{pmatrix}$$

Обойтись без моделей: итоги

- Помните о случайном лесе, градиентном бустинге и даже об обычной регрессии.

Обойтись без моделей: итоги

- Помните о случайном лесе, градиентном бустинге и даже об обычной регрессии.
- Добавьте лаги зависимой переменной.

Обойтись без моделей: итоги

- Помните о случайном лесе, градиентном бустинге и даже об обычной регрессии.
- Добавьте лаги зависимой переменной.
- Добавьте агрегирующие функции скользящим и растущим окном.

У нас есть ещё время!

У нас ещё есть время: план

- Предикторы тренда.

У нас ещё есть время: план

- Предикторы тренда.
- Сезонные и праздничные дамми.

У нас ещё есть время: план

- Предикторы тренда.
- Сезонные и праздничные дамми.
- Косинусы и синусы.

Используем время!

Для примера возьмём t и \sqrt{t} .

Используем время!

Для примера возьмём t и \sqrt{t} .

Обучающая выборка:

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} 1 & \sqrt{1} \\ 2 & \sqrt{2} \\ 3 & \sqrt{3} \\ \vdots & \vdots \\ T & \sqrt{T} \end{pmatrix}$$

Используем время!

Для примера возьмём t и \sqrt{t} .

Обучающая выборка:

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} 1 & \sqrt{1} \\ 2 & \sqrt{2} \\ 3 & \sqrt{3} \\ \vdots & \vdots \\ T & \sqrt{T} \end{pmatrix}$$

Выборка для прогнозирования:

$$\begin{pmatrix} ? \end{pmatrix} \quad \begin{pmatrix} T + 1 & \sqrt{T + 1} \end{pmatrix}$$

Включать ли монотонные преобразования времени?

- Всегда можно попробовать включить!

Включать ли монотонные преобразования времени?

- Всегда **можно попробовать** включить!
- Алгоритмам основанным на построении **деревьев** (случайные лес, градиентный бустинг) дополнительные монотонные преобразования времени **бесполезны**.

Включать ли монотонные преобразования времени?

- Всегда **можно попробовать** включить!
- Алгоритмам основанным на построении **деревьев** (случайные лес, градиентный бустинг) дополнительные монотонные преобразования времени **бесполезны**.
- Помните о возможном преобразовании **исходной переменной** (логарифм, преобразование Бокса-Кокса).

Сезонные и праздничные дамми

Если сезонов **немного**, то разумно включить дамми на каждый сезон.

Сезонные и праздничные дамми

Если сезонов **немного**, то разумно включить дамми на каждый сезон.

Обучающая выборка для квартальных данных:

$$\begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \\ y_6 \\ \vdots \\ y_T \end{pmatrix} \quad \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & 1 & 0 \end{pmatrix}$$

Ловушка дамми-переменных

В регрессии помните о ловушке дамми-переменных!

Ловушка дамми-переменных

В регрессии помните о ловушке дамми-переменных!

- Либо дамми на каждый сезон и модель без константы.

Ловушка дамми-переменных

В регрессии помните о ловушке дамми-переменных!

- Либо дамми на каждый сезон и модель без константы.
- Либо дамми на все сезоны кроме одного и модель с константой.

Ловушка дамми-переменных

В регрессии помните о ловушке дамми-переменных!

- Либо дамми на каждый сезон и модель без константы.
- Либо дамми на все сезоны кроме одного и модель с константой.

Ловушка дамми-переменных

В **регрессии** помните о **ловушке** дамми-переменных!

- Либо дамми на каждый сезон и модель без константы.
- Либо дамми на все сезоны кроме одного и модель с константой.

Алгоритмы основанные на построении **деревьев** (случайные лес, градиентный бустинг) **устойчивы** к ловушке дамми.

Зачем нужны синусы и косинусы?

Стратегия добавления всех дамми переменных **плохо** работает, если их нужно **много**.

Зачем нужны синусы и косинусы?

Стратегия добавления всех дамми переменных **плохо** работает, если их нужно **много**.

Вряд ли стоит добавлять 365 дамми-переменных для **дневных** данных.

Зачем нужны синусы и косинусы?

Стратегия добавления всех дамми переменных **плохо** работает, если их нужно **много**.

Вряд ли стоит добавлять 365 дамми-переменных для **дневных** данных.

Обойтись **малым числом** предикторов помогут синус и косинус!

Зачем нужны синусы и косинусы?

Стратегия добавления всех дамми переменных **плохо** работает, если их нужно **много**.

Вряд ли стоит добавлять 365 дамми-переменных для **дневных** данных.

Обойтись **малым числом** предикторов помогут синус и косинус!

Два факта:

- Период у $\sin t$ и $\cos t$ равен 2π ;

Зачем нужны синусы и косинусы?

Стратегия добавления всех дамми переменных **плохо** работает, если их нужно **много**.

Вряд ли стоит добавлять 365 дамми-переменных для **дневных** данных.

Обойтись **малым числом** предикторов помогут синус и косинус!

Два факта:

- Период у $\sin t$ и $\cos t$ равен 2π ;
- При умножении аргумента на a период **сокращается** в a раз.

Разложение Фурье

Теорема

Любая непрерывная и дифференцируемая функция f с периодом 2π может быть представлена в виде

$$f(t) = c + \sum_{k=1}^{\infty} a_k \cos(kt) + b_k \sin(kt).$$

Разложение Фурье

Теорема

Любая непрерывная и дифференцируемая функция f с периодом 2π может быть представлена в виде

$$f(t) = c + \sum_{k=1}^{\infty} a_k \cos(kt) + b_k \sin(kt).$$

Практический рецепт для дневных данных:

- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot t\right)$;

Разложение Фурье

Теорема

Любая непрерывная и дифференцируемая функция f с периодом 2π может быть представлена в виде

$$f(t) = c + \sum_{k=1}^{\infty} a_k \cos(kt) + b_k \sin(kt).$$

Практический рецепт для дневных данных:

- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot t\right)$;
- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot 2t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot 2t\right)$;

Разложение Фурье

Теорема

Любая непрерывная и дифференцируемая функция f с периодом 2π может быть представлена в виде

$$f(t) = c + \sum_{k=1}^{\infty} a_k \cos(kt) + b_k \sin(kt).$$

Практический рецепт для дневных данных:

- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot t\right)$;
- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot 2t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot 2t\right)$;
- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot 3t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot 3t\right)$;

Разложение Фурье

Теорема

Любая непрерывная и дифференцируемая функция f с периодом 2π может быть представлена в виде

$$f(t) = c + \sum_{k=1}^{\infty} a_k \cos(kt) + b_k \sin(kt).$$

Практический рецепт для дневных данных:

- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot t\right)$;
- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot 2t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot 2t\right)$;
- Добавьте предикторы $\cos\left(\frac{2\pi}{365} \cdot 3t\right)$ и $\sin\left(\frac{2\pi}{365} \cdot 3t\right)$;
- ...

У нас есть ещё время: итоги

- Используйте **время** в качестве предиктора.

У нас есть ещё время: итоги

- Используйте **время** в качестве предиктора.
- Сезонность в предикторах можно отразить с помощью **дамми-переменных** или с помощью **косинуса** и **синуса**.

Случайный лес и градиентный бустинг

Случайный лес и градиентный бустинг: план

- Деревья для случайного леса.

Случайный лес и градиентный бустинг: план

- Деревья для случайного леса.
- Деревья для градиентного бустинга.

Случайный лес

Особенности деревьев:

- Деревьев очень **много**, $n_{tree} = 10000$.

Случайный лес

Особенности деревьев:

- Деревьев очень **много**, $n_{tree} = 10000$.
- Деревья очень **ветвистые**.

Случайный лес

Особенности деревьев:

- Деревьев очень **много**, $n_{tree} = 10000$.
- Деревья очень **ветвистые**.
- Деревья равноправные: лес **усредняет** прогнозы деревьев.

Почему деревья разные?

Два источника случайности:

- Каждое дерево растёт случайно.

Каждое дерево в **каждом своём узле** из большого исходного списка предикторов **удаляет** случайным образом часть предикторов перед поиском оптимального деления.

Почему деревья разные?

Два источника случайности:

- Каждое дерево растёт случайно.
Каждое дерево в **каждом своём узле** из большого исходного списка предикторов **удаляет** случайным образом часть предикторов перед поиском оптимального деления.
- Каждое дерево растёт на своей бутстрэп выборке.
Из исходных T наблюдений перед построением дерева создаётся новая **искусственная выборка с возвращением** в T наблюдений.

Бутстрэп выборка

Исходная выборка:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} \quad X = \begin{pmatrix} a_1 & b_1 \\ a_2 & b_2 \\ a_3 & b_3 \\ a_4 & b_4 \\ a_5 & b_5 \end{pmatrix}$$

Бутстрэп выборка

Исходная выборка:

$$y = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix} \quad X = \begin{pmatrix} a_1 & b_1 \\ a_2 & b_2 \\ a_3 & b_3 \\ a_4 & b_4 \\ a_5 & b_5 \end{pmatrix}$$

Пример бутстрэп выборки:

$$y^* = \begin{pmatrix} y_4 \\ y_2 \\ y_1 \\ y_4 \\ y_1 \end{pmatrix} \quad X^* = \begin{pmatrix} a_4 & b_4 \\ a_2 & b_2 \\ a_1 & b_1 \\ a_4 & b_4 \\ a_1 & b_1 \end{pmatrix}$$

Лес в формулах

Построение **деревьев**:

- Из (y, X) случайно создаём первую бутстрэп выборку (y^*, X^*) .

Первое дерево T_1 учится прогнозировать y^* с помощью X^* .

Лес в формулах

Построение **деревьев**:

- Из (y, X) случайно создаём первую бутстрэп выборку (y^*, X^*) .

Первое дерево T_1 учится прогнозировать y^* с помощью X^* .

- Из (y, X) случайно создаём вторую бутстрэп выборку (y^*, X^*) .

Второе дерево T_2 учится прогнозировать y^* с помощью X^* .

Лес в формулах

Построение **деревьев**:

- Из (y, X) случайно создаём первую бутстрэп выборку (y^*, X^*) .

Первое дерево T_1 учится прогнозировать y^* с помощью X^* .

- Из (y, X) случайно создаём вторую бутстрэп выборку (y^*, X^*) .

Второе дерево T_2 учится прогнозировать y^* с помощью X^* .

- ...

Лес в формулах

Построение **деревьев**:

- Из (y, X) случайно создаём первую бутстрэп выборку (y^*, X^*) .

Первое дерево T_1 учится прогнозировать y^* с помощью X^* .

- Из (y, X) случайно создаём вторую бутстрэп выборку (y^*, X^*) .

Второе дерево T_2 учится прогнозировать y^* с помощью X^* .

- ...

Лес в формулах

Построение **деревьев**:

- Из (y, X) случайно создаём первую бутстрэп выборку (y^*, X^*) .

Первое дерево T_1 учится прогнозировать y^* с помощью X^* .

- Из (y, X) случайно создаём вторую бутстрэп выборку (y^*, X^*) .

Второе дерево T_2 учится прогнозировать y^* с помощью X^* .

- ...

Построение **прогнозов**:

$$\text{Forest}(x) = \frac{1}{n_{tree}}(T_1(x) + T_2(x) + \dots + T_{n_{tree}}(x))$$

Градиентный бустинг

Особенности деревьев:

- Деревьев относительно **мало**, вполне возможно, $n_{tree} = 1000$.

Градиентный бустинг

Особенности деревьев:

- Деревьев относительно **мало**, вполне возможно, $n_{tree} = 1000$.
- Деревья не очень **ветвистые**.

Градиентный бустинг

Особенности деревьев:

- Деревьев относительно **мало**, вполне возможно, $n_{tree} = 1000$.
- Деревья не очень **ветвистые**.
- Каждое последующее дерево **уточняет** суммарный прогноз предыдущих деревьев с весом η .

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

- Первое дерево T_1 учится прогнозировать $r_0 = y - GB_0(X)$ с помощью X .

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

- Первое дерево T_1 учится прогнозировать

$r_0 = y - GB_0(X)$ с помощью X .

- Составляем композитный прогноз:

$$GB_1(x) = GB_0(x) + \eta T_1(x) = \bar{y} + \eta T_1(x).$$

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

- Первое дерево T_1 учится прогнозировать $r_0 = y - GB_0(X)$ с помощью X .
- Составляем композитный прогноз:

$$GB_1(x) = GB_0(x) + \eta T_1(x) = \bar{y} + \eta T_1(x).$$

- Второе дерево T_2 учится прогнозировать $r_1 = y - GB_1(X)$ с помощью X .

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

- Первое дерево T_1 учится прогнозировать $r_0 = y - GB_0(X)$ с помощью X .
- Составляем композитный прогноз:

$$GB_1(x) = GB_0(x) + \eta T_1(x) = \bar{y} + \eta T_1(x).$$

- Второе дерево T_2 учится прогнозировать $r_1 = y - GB_1(X)$ с помощью X .
- Составляем композитный прогноз:

$$GB_2(x) = GB_1(x) + \eta T_2(x) = \bar{y} + \eta(T_1(x) + T_2(x)).$$

Бустинг в формулах

Построение **деревьев** и прогнозов:

- Без деревьев прогноз тривиален:

$$GB_0(x) = \bar{y} = \frac{y_1 + y_2 + \dots + y_T}{T}$$

- Первое дерево T_1 учится прогнозировать $r_0 = y - GB_0(X)$ с помощью X .
- Составляем композитный прогноз:

$$GB_1(x) = GB_0(x) + \eta T_1(x) = \bar{y} + \eta T_1(x).$$

- Второе дерево T_2 учится прогнозировать $r_1 = y - GB_1(X)$ с помощью X .
- Составляем композитный прогноз:

$$GB_2(x) = GB_1(x) + \eta T_2(x) = \bar{y} + \eta(T_1(x) + T_2(x)).$$

- ...

Как сравнить алгоритмы?

- Нельзя применять критерий Акаике AIC .

Как сравнить алгоритмы?

- Нельзя применять критерий Акаике AIC .
- Можно применять **кросс-валидацию!**
Можно даже применять **кросс-валидацию** для **перекрестных данных!**

Случайный лес и градиентный бустинг: итоги

- У алгоритмов **куча вариаций**.

Случайный лес и градиентный бустинг: итоги

- У алгоритмов **куча вариаций**.
- В лесу много **равноправных деревьев** и они **ветвистые**.

Случайный лес и градиентный бустинг: итоги

- У алгоритмов **куча вариаций**.
- В лесу много **равноправных деревьев** и они **ветвистые**.
- В градиентном бустинге деревьев мало, они **небольшие** и каждое последующее дерево **уточняет** прогнозы.

Случайный лес и градиентный бустинг: итоги

- У алгоритмов **куча вариаций**.
- В лесу много **равноправных деревьев** и они **ветвистые**.
- В градиентном бустинге деревьев мало, они **небольшие** и каждое последующее дерево **уточняет** прогнозы.
- Для случайного леса стоит взять **побольше деревьев**.

Случайный лес и градиентный бустинг: итоги

- У алгоритмов **куча вариаций**.
- В лесу много **равноправных деревьев** и они **ветвистые**.
- В градиентном бустинге деревьев мало, они **небольшие** и каждое последующее дерево **уточняет** прогнозы.
- Для случайного леса стоит взять **побольше деревьев**.
- В градиентном бустинге важен баланс **числа деревьев** и **темпа обучения**.

Предикторы и *ARIMA*

Предикторы и $ARIMA$: план

- Регрессия с $ARMA$ ошибками.

Предикторы и $ARIMA$: план

- Регрессия с $ARMA$ ошибками.
- $ARMAX$ модель.

Предикторы и $ARIMA$: план

- Регрессия с $ARMA$ ошибками.
- $ARMAX$ модель.
- $ARDL$ модель.

Регрессия с $ARMA$ ошибками

Уравнение

$$y_t = \beta_1 + \beta_2 a_t + \beta_3 b_t + \varepsilon_t,$$

где a_t и b_t — предикторы.

Регрессия с *ARMA* ошибками

Уравнение

$$y_t = \beta_1 + \beta_2 a_t + \beta_3 b_t + \varepsilon_t,$$

где a_t и b_t — предикторы.

- Ряды (y_t) , (a_t) , (b_t) , (ε_t) стационарны.
- $\varepsilon_t \sim ARMA(p, q)$ относительно белого шума (u_t) .
- $\mathbb{E}(\varepsilon_t \mid a_{t-1}, b_{t-1}, a_{t-2}, b_{t-2}, \dots) = 0$.
- Четвертые моменты предикторов конечны.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

- Ряды (y_t) , (a_t) , (b_t) стационарны.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

- Ряды (y_t) , (a_t) , (b_t) стационарны.
- $\mathbb{E}(u_t \mid a_{t-1}, b_{t-1}, y_{t-1}, a_{t-2}, b_{t-2}, y_{t-2}, \dots) = 0$.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

- Ряды (y_t) , (a_t) , (b_t) стационарны.
- $\mathbb{E}(u_t \mid a_{t-1}, b_{t-1}, y_{t-1}, a_{t-2}, b_{t-2}, y_{t-2}, \dots) = 0$.
- Четвертые моменты предикторов конечны.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

- Ряды (y_t) , (a_t) , (b_t) стационарны.
- $\mathbb{E}(u_t \mid a_{t-1}, b_{t-1}, y_{t-1}, a_{t-2}, b_{t-2}, y_{t-2}, \dots) = 0$.
- Четвертые моменты предикторов конечны.

ARMAX модель

Уравнение

$$y_t = c + \gamma_1 a_t + \gamma_2 b_t + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + u_t + \alpha_1 u_{t-1} + \dots + \alpha_q u_{t-q},$$

где a_t и b_t — предикторы, а (u_t) — белый шум.

- Ряды (y_t) , (a_t) , (b_t) стационарны.
- $\mathbb{E}(u_t \mid a_{t-1}, b_{t-1}, y_{t-1}, a_{t-2}, b_{t-2}, y_{t-2}, \dots) = 0$.
- Четвертые моменты предикторов конечны.

ARMAX модель не полностью эквивалентна регрессии с ARMA ошибками, но качество прогнозов у моделей примерно одинаковое.

Свойства $ARMAX$ модели и регрессии с $ARMA$ ошибками

1. Если выполнены предпосылки, то оценки метода максимального правдоподобия **состоятельны**.
2. Для нестационарных переменных (y_t) и предикторов (a_t) и (b_t) можно перейти к первым **разностям**.
3. Оценки **останутся** состоятельны, если добавить тренд, дамми на сезонность и тригонометрические предикторы.
4. **Не любой** предиктор даёт возможность получить состоятельную оценку коэффициента.
5. **Иногда** можно получить хорошие прогнозы, даже если предпосылки нарушены.

ARDL модель

ARDL — AutoRegressive Distributed Lag model

Авторегрессионная модель с распределёнными лагами.

Уравнение $ARDL(p, q)$ модели

$$y_t = c + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + x_t + \alpha_1 x_{t-1} + \dots + \alpha_q x_{t-q} + u_t$$

ARDL модель

ARDL — **A**uto**R**egressive **D**istributed **L**ag model

Авторегрессионная модель с распределёнными лагами.

Уравнение $ARDL(p, q)$ модели

$$y_t = c + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + x_t + \alpha_1 x_{t-1} + \dots + \alpha_q x_{t-q} + u_t$$

- Ошибки (u_t) являются белым шумом.

ARDL модель

ARDL — AutoRegressive Distributed Lag model

Авторегрессионная модель с распределёнными лагами.

Уравнение $ARDL(p, q)$ модели

$$y_t = c + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + x_t + \alpha_1 x_{t-1} + \dots + \alpha_q x_{t-q} + u_t$$

- Ошибки (u_t) являются белым шумом.
- Процесс (x_t) или процесс (Δx_t) является стационарным.

ARDL модель

ARDL — AutoRegressive Distributed Lag model

Авторегрессионная модель с распределёнными лагами.

Уравнение $ARDL(p, q)$ модели

$$y_t = c + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + x_t + \alpha_1 x_{t-1} + \dots + \alpha_q x_{t-q} + u_t$$

- Ошибки (u_t) являются белым шумом.
- Процесс (x_t) или процесс (Δx_t) является стационарным.
- Процесс (y_t) является нестационарным, но (Δy_t) является стационарным.

ARDL модель

ARDL — AutoRegressive Distributed Lag model

Авторегрессионная модель с распределёнными лагами.

Уравнение $ARDL(p, q)$ модели

$$y_t = c + \beta_1 y_{t-1} + \dots + \beta_p y_{t-p} + x_t + \alpha_1 x_{t-1} + \dots + \alpha_q x_{t-q} + u_t$$

- Ошибки (u_t) являются белым шумом.
- Процесс (x_t) или процесс (Δx_t) является стационарным.
- Процесс (y_t) является нестационарным, но (Δy_t) является стационарным.
- $\mathbb{E}(u_t \mid y_{t-1}, x_{t-1}, y_{t-2}, x_{t-2}, \dots) = 0$.

Свойства $ARDL$ модели

- Вместо лагов шума (u_t) лаги предиктора (x_t) .

Свойства *ARDL* модели

- Вместо лагов шума (u_t) лаги предиктора (x_t) .
- Подходит для нестационарного (y_t) .

Свойства *ARDL* модели

- Вместо лагов шума (u_t) лаги предиктора (x_t) .
- Подходит для нестационарного (y_t) .
- Используют для нахождения долгосрочных взаимоотношений между рядами.

Свойства *ARDL* модели

- Вместо лагов шума (u_t) лаги предиктора (x_t) .
- Подходит для нестационарного (y_t) .
- Используют для нахождения долгосрочных взаимоотношений между рядами.
- Если предпосылки выполнены, то оценки МНК состоятельны, хотя и смещены.

Свойства *ARDL* модели

- Вместо лагов шума (u_t) лаги предиктора (x_t).
- Подходит для нестационарного (y_t).
- Используют для нахождения долгосрочных взаимоотношений между рядами.
- Если предпосылки выполнены, то оценки МНК состоятельны, хотя и смещены.
- Можно добавить несколько предикторов с разным числом лагов.

Предикторы и $ARIMA$: итоги

- Для **стационарных данных** можно использовать регрессию с $ARMA$ ошибками или $ARMAX$ модель.

Предикторы и $ARIMA$: итоги

- Для **стационарных данных** можно использовать регрессию с $ARMA$ ошибками или $ARMAX$ модель.
- Регрессию с $ARMA$ ошибками можно строить **в разностях**.

Предикторы и *ARIMA*: итоги

- Для **стационарных данных** можно использовать регрессию с *ARMA* ошибками или *ARMAX* модель.
- Регрессию с *ARMA* ошибками можно строить **в разностях**.
- Для **нестационарных рядов** иногда можно использовать *ARDL* модель.