

Пропуски, аномалии и структурные сдвиги

Заполнение пропусков

Заполнение пропусков: план

- Линейная интерполяция.

Заполнение пропусков: план

- Линейная интерполяция.
- Модели для заполнения пропусков.

Заполнение пропусков: план

- Линейная интерполяция.
- Модели для заполнения пропусков.
- Использование STL-разложения.

Линейная интерполяция

Идея

Заполним пропуски так, чтобы восстановленные значения идеально ложились на прямую (образовывали арифметическую прогрессию),

$$\Delta y_t^{imp} = const.$$

Линейная интерполяция

Идея

Заполним пропуски так, чтобы восстановленные значения идеально ложились на прямую (образовывали арифметическую прогрессию),

$$\Delta y_t^{imp} = const.$$

Пример:

10, NA, NA, 100.

Линейная интерполяция

Идея

Заполним пропуски так, чтобы восстановленные значения идеально ложились на прямую (образовывали арифметическую прогрессию),

$$\Delta y_t^{imp} = const.$$

Пример:

10, NA, NA, 100.

10, 40, 70, 100

Модели для заполнения пропусков

1. Оцениваем модель, **допускающую** пропуски в данных.
ARIMA подходит! И автоматическая ARIMA тоже!

Модели для заполнения пропусков

1. Оцениваем модель, **допускающую** пропуски в данных. ARIMA подходит! И автоматическая ARIMA тоже!
2. Пропущенные значения y_t заменяем на условное математическое ожидание, полагая оценённые параметры модели равным истинными,

$$y_t^{imp} = \mathbb{E}(y_t \mid \text{данные}).$$

Используется **фильтр Калмана**.

Модели для заполнения пропусков

1. Оцениваем модель, **допускающую** пропуски в данных. ARIMA подходит! И автоматическая ARIMA тоже!
2. Пропущенные значения y_t заменяем на условное математическое ожидание, полагая оценённые параметры модели равным истинными,

$$y_t^{imp} = \mathbb{E}(y_t \mid \text{данные}).$$

Используется **фильтр Калмана**.

Модели для заполнения пропусков

1. Оцениваем модель, **допускающую** пропуски в данных. ARIMA подходит! И автоматическая ARIMA тоже!
2. Пропущенные значения y_t заменяем на условное математическое ожидание, полагая оценённые параметры модели равным истинными,

$$y_t^{imp} = \mathbb{E}(y_t \mid \text{данные}).$$

Используется **фильтр Калмана**.

Возможность оценивать модель на данных с пропусками сильно зависит от **реализации**.

Использование STL-разложения

1. Раскладываем ряд с пропусками на составляющие:

$$y_t = \text{trend}_t + \text{seasonal}_t + \text{remainder}_t = \text{seasonal}_t + \text{deseason}_t.$$

STL восстанавливает **сезонную компоненту** без пропусков!

Использование STL-разложения

1. Раскладываем ряд с пропусками на составляющие:

$$y_t = \text{trend}_t + \text{seasonal}_t + \text{remainder}_t = \text{seasonal}_t + \text{deseason}_t.$$

STL восстанавливает **сезонную компоненту** без пропусков!

2. Восстанавливаем пропущенные значения десезонированного ряда **линейной** интерполяцией.

Использование STL-разложения

1. Раскладываем ряд с пропусками на составляющие:

$$y_t = \text{trend}_t + \text{seasonal}_t + \text{remainder}_t = \text{seasonal}_t + \text{deseason}_t.$$

STL восстанавливает **сезонную компоненту** без пропусков!

2. Восстанавливаем пропущенные значения десезонированного ряда **линейной** интерполяцией.
3. Пропущенные значения y_t заменяем на сумму восстановленных десезонированных значений и сезонной составляющей,

$$y_t^{imp} = \text{seasonal}_t + \text{deseason}_t^{imp}.$$

Зачем заполнять пропуски?

- Иногда заполнение пропусков — основная задача.

Зачем заполнять пропуски?

- Иногда заполнение пропусков — основная задача.
- Возможность использовать больше алгоритмов прогнозирования для восстановленного ряда.

Зачем заполнять пропуски?

- Иногда заполнение пропусков — основная задача.
- Возможность использовать больше алгоритмов прогнозирования для восстановленного ряда.
- Возможность использовать восстановленный ряд как предиктор.

Заполнение пропусков: итоги

- Линейная интерполяция: просто и быстро!

Заполнение пропусков: итоги

- Линейная **интерполяция**: просто и быстро!
- Использование **ARIMA** или более сложных моделей.

Заполнение пропусков: итоги

- Линейная **интерполяция**: просто и быстро!
- Использование **ARIMA** или более сложных моделей.
- **STL-разложение** и восстановление компонент.

Заполнение пропусков: итоги

- Линейная **интерполяция**: просто и быстро!
- Использование **ARIMA** или более сложных моделей.
- **STL-разложение** и восстановление компонент.
- **Вариации** у каждого алгоритма.

Байесовские структурные модели

Байесовские структурные модели: план

- Как добавить предикторы в ETS ?

Байесовские структурные модели: план

- Как добавить предикторы в ETS ?
- Идея байесовского подхода.

Байесовские структурные модели: план

- Как добавить предикторы в ETS ?
- Идея байесовского подхода.
- Пример структурной модели.

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.
- А **что мешает** их туда добавить и получить новую модель?

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.
- А **что мешает** их туда добавить и получить новую модель?
В новой модели может оказаться **слишком много** параметров.

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.
- А **что мешает** их туда добавить и получить новую модель?
В новой модели может оказаться **слишком много** параметров.
Качество прогнозов может быть плохим.

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.
- А **что мешает** их туда добавить и получить новую модель?
В новой модели может оказаться **слишком много** параметров.
Качество прогнозов может быть плохим.
- Спасительная идея — **регуляризация**.

Как добавить предикторы в *ETS*?

- Классическая *ETS* модель **не позволяет** включать предикторы.
- А **что мешает** их туда добавить и получить новую модель?
В новой модели может оказаться **слишком много** параметров.
Качество прогнозов может быть плохим.
- Спасительная идея — **регуляризация**.
Рассматриваем модель с большим числом параметров и дополнительной информацией, что параметры **небольшие**.

Байесовский подход!

- Трактуем все параметры как ненаблюдаемые **случайные величины**, $\theta = (a, b, c)$.

Байесовский подход!

- Трактуем все параметры как ненаблюдаемые **случайные величины**, $\theta = (a, b, c)$.
- **Модель** задаёт распределение ряда при заданных параметрах,

$$y_t = a + u_t + bu_{t-1}, \quad u_t \sim \mathcal{N}(0; c).$$

Байесовский подход!

- Трактуем все параметры как ненаблюдаемые **случайные величины**, $\theta = (a, b, c)$.
- **Модель** задаёт распределение ряда при заданных параметрах,

$$y_t = a + u_t + bu_{t-1}, \quad u_t \sim \mathcal{N}(0; c).$$

- Добавляем информацию в виде **априорного распределения**,

$$a \sim \mathcal{N}(0; 100), \quad b \sim \mathcal{N}(0, 1), \quad \ln c \sim \mathcal{N}(0; 4).$$

Байесовский подход!

- Трактуем все параметры как ненаблюдаемые **случайные величины**, $\theta = (a, b, c)$.
- **Модель** задаёт распределение ряда при заданных параметрах,

$$y_t = a + u_t + bu_{t-1}, \quad u_t \sim \mathcal{N}(0; c).$$

- Добавляем информацию в виде **априорного распределения**,

$$a \sim \mathcal{N}(0; 100), \quad b \sim \mathcal{N}(0, 1), \quad \ln c \sim \mathcal{N}(0; 4).$$

- Алгоритмы MCMC (Markov Chain Monte Carlo) позволяют сгенерировать большую выборку из **апостериорное распределение**

$$(a, b, c \mid y_1, y_2, \dots, y_T).$$

Немного про МСМС

- Выборка из апостериорного распределения $(\theta \mid y)$ позволяет считать **всё!**

$$(a_1, b_1, c_1), (a_2, b_2, c_2), \dots, (a_S, b_S, c_S).$$

Немного про МСМС

- Выборка из апостериорного распределения $(\theta \mid y)$ позволяет считать **всё!**

$$(a_1, b_1, c_1), (a_2, b_2, c_2), \dots, (a_S, b_S, c_S).$$

- Имея значения параметров можно симулировать **будущие траектории.**

Немного про МСМС

- Выборка из апостериорного распределения $(\theta \mid y)$ позволяет считать **всё!**

$$(a_1, b_1, c_1), (a_2, b_2, c_2), \dots, (a_S, b_S, c_S).$$

- Имея значения параметров можно симулировать **будущие траектории**.
- МСМС позволяет работать с моделями **фантастической сложности**.

Немного про МСМС

- Выборка из апостериорного распределения $(\theta \mid y)$ позволяет считать **всё!**

$$(a_1, b_1, c_1), (a_2, b_2, c_2), \dots, (a_S, b_S, c_S).$$

- Имея значения параметров можно симулировать **будущие траектории**.
- МСМС позволяет работать с моделями **фантастической сложности**.
- МСМС работает **медленно**.

Немного про МСМС

- Выборка из апостериорного распределения $(\theta \mid y)$ позволяет считать **всё!**

$$(a_1, b_1, c_1), (a_2, b_2, c_2), \dots, (a_S, b_S, c_S).$$

- Имея значения параметров можно симулировать **будущие траектории**.
- МСМС позволяет работать с моделями **фантастической сложности**.
- МСМС работает **медленно**.
- Генерируемая выборка только **в пределе** похожа на выборку из апостериорного закона.

Конструктор структурных моделей

Байесовские структурные модели: итоги

- Трактуем параметры как случайные величины.

Байесовские структурные модели: итоги

- Трактует параметры как случайные величины.
- Конструируем из кубиков настоящего монстра с предикторами.

Байесовские структурные модели: итоги

- Трактуем параметры как случайные величины.
- Конструируем из кубиков настоящего монстра с предикторами.
- MCMC работает медленно.

Байесовские структурные модели: итоги

- Трактуем параметры как **случайные величины**.
- Конструируем из кубиков **настоящего монстра** с предикторами.
- MCMC работает **медленно**.
- С помощью MCMC можно сгенерировать большую выборку из **апостериорного** распределения параметров.

Как оценить эффект воздействия?

Оценивание эффекта: план

- Основная идея оценивания.

Оценивание эффекта: план

- Основная идея оценивания.
- Чем хорош байесовский подход?

Оценивание эффекта: идея

- Возьмём **любую** модель.

Оценивание эффекта: идея

- Возьмём **любую** модель.
- Разделим выборку на обучающую и тестовую **по точке воздействия**.

Оценивание эффекта: идея

- Возьмём **любую** модель.
- Разделим выборку на обучающую и тестовую **по точке воздействия**.
- Оценим модель по обучающей выборке и **получим прогноз**.

Оценивание эффекта: идея

- Возьмём **любую** модель.
- Разделим выборку на обучающую и тестовую **по точке воздействия**.
- Оценим модель по обучающей выборке и **получим прогноз**.
- **Разница** прогноза и фактических значений на тестовой выборке оценивает эффект воздействия.

Нюансы идеи

- Модель должна **хорошо** прогнозировать.

Нюансы идеи

- Модель должна **хорошо** прогнозировать.
Если сезонность сильна, то даже **наивная сезонная** модель подойдёт.

Нюансы идеи

- Модель должна **хорошо** прогнозировать.
Если сезонность сильна, то даже **наивная сезонная** модель подойдёт.
- Разумно **протестировать идею** в точке, где воздействия ещё нет.

Нюансы идеи

- Модель должна **хорошо** прогнозировать.
Если сезонность сильна, то даже **наивная сезонная** модель подойдёт.
- Разумно **протестировать идею** в точке, где воздействия ещё нет.
- Можно оценивать эффект воздействия на конкретное значение y_{T+h} , а можно оценивать **кумулятивный эффект** на $y_{T+1} + y_{T+2} + \dots + y_{T+h}$.

Нюансы идеи

- Модель должна **хорошо** прогнозировать.
Если сезонность сильна, то даже **наивная сезонная** модель подойдёт.
- Разумно **протестировать идею** в точке, где воздействия ещё нет.
- Можно оценивать эффект воздействия на конкретное значение y_{T+h} , а можно оценивать **кумулятивный эффект** на $y_{T+1} + y_{T+2} + \dots + y_{T+h}$.
- Помните о **доверительных** интервалах.

А зачем тут байесовский подход?

- Позволяет оценивать более сложные модели с предикторами.

А зачем тут байесовский подход?

- Позволяет оценивать более сложные модели с предикторами.

Возможность более точно оценить эффект воздействия.

А зачем тут байесовский подход?

- Позволяет оценивать более сложные модели с предикторами.

Возможность более точно оценить эффект воздействия.

- Позволяет построить доверительный интервал для кумулятивного эффекта.

А зачем тут байесовский подход?

- Позволяет оценивать **более сложные** модели с предикторами.

Возможность более точно оценить эффект воздействия.

- Позволяет построить **доверительный интервал** для кумулятивного эффекта.

Проблема: прогнозы $\hat{y}_{T+1}, \dots, \hat{y}_{T+h}$ нетривиально коррелированы между собой. В частотном подходе сложно получить **явную формулу** для доверительного интервала.

А зачем тут байесовский подход?

- Позволяет оценивать **более сложные** модели с предикторами.

Возможность более точно оценить эффект воздействия.

- Позволяет построить **доверительный интервал** для кумулятивного эффекта.

Проблема: прогнозы $\hat{y}_{T+1}, \dots, \hat{y}_{T+h}$ нетривиально коррелированы между собой. В частотном подходе сложно получить **явную формулу** для доверительного интервала.

Решение: в байесовском подходе апостериорная выборка параметров модели позволяет сгенерировать множество **гипотетических будущих** траекторий без воздействия.

А зачем тут байесовский подход?

- Позволяет оценивать **более сложные** модели с предикторами.

Возможность более точно оценить эффект воздействия.

- Позволяет построить **доверительный интервал** для кумулятивного эффекта.

Проблема: прогнозы $\hat{y}_{T+1}, \dots, \hat{y}_{T+h}$ нетривиально коррелированы между собой. В частотном подходе сложно получить **явную формулу** для доверительного интервала.

Решение: в байесовском подходе апостериорная выборка параметров модели позволяет сгенерировать множество **гипотетических будущих** траекторий без воздействия.

- Графики **будущих** траекторий!

Оценивание эффекта воздействия: итоги

- Делим выборку на обучающую и тестовую **в точке воздействия**.

Оценивание эффекта воздействия: итоги

- Делим выборку на обучающую и тестовую **в точке воздействия**.
- Смотрим на **разницу** прогноза модели и фактических значений.

Оценивание эффекта воздействия: итоги

- Делим выборку на обучающую и тестовую **в точке воздействия**.
- Смотрим на **разницу** прогноза модели и фактических значений.
- Байесовский подход дарит **доверительные интервалы** для кумулятивного эффекта.